Name : Krisnanto
NIM : 26/579951/PPA/07302

1. Perumusan Proyek
    a. Proyek ini membantu KopiNusa untuk mengurangi berhentinya anggota bertransaksi dan untuk mendukung peningkatan penjualan.
    b. Menentukan anggota yang diprioritaskan untuk dihubungi atau ditawari program retensi. Jumlah anggota yang menerima program disesuaikan dengan anggaran pemasaran.
    c. Tim pemasaran menentukan sasaran dan bentuk program retensi, sedangkan Owner menetapkan anggaran dan mengevaluasi dampak bisnisnya.
    d. Menentukan probabilitas seorang anggota tidak melakukan transaksi sama sekali selama 1 Juli sampai 30 September 2026. Kita bisa memakai kolom *berhenti* pada file ***anggota.csv*** sebagai target dengan value **ya** sebagai kelas positif dan **tidak** sebagai kelas negatif.
    e. Satu baris tabel pemodelan mewakili satu anggota unik, berisi atribut anggota, ringkasan transaksi sebelum batas fitur, dan label berhenti. Transaksi diringkas per anggota menggunakan id_anggota sebagai kunci penghubung.
    f. Waktu prediksi disimulasikan pada awal 1 Juli 2026, sebelum mengamati transaksi pada periode Juli – September 2026.
    g. Periode fitur: 1 Januari – 30 Juni 2026; batas akhir fitur: 30 Juni 2026.
    h. Outcome window pada 1 Juli sampai 30 September 2026. Berhenti berarti tidak aktif bertransaksi selama periode tersebut. Belum bisa dipastikan berhenti permanen sebagai pelanggan.
    i. Keberhasilan bisnis dinilai dari proporsi anggota tidak aktif yang lebih rendah dan penjualan per anggota yang lebih tinggi pada kelompok penerima program dibandingkan kelompok pembanding dalam periode yang sama. Kinerja prediksi model dinilai menggunakan ROC-AUC.

2. Pemeriksaan kualitas data dilakukan pada file **anggota.csv** dan **transaksi.csv** sebelum digunakan untuk analisis.
    a. Kondisi awal data dari hasil pembacaan csv di notebook.

File CSV	Jumlah Baris Awal	Jumlah Kolom
anggota	1.500	9
transaksi	36.175	9

Seluruh kolom dibaca sebagai text untuk mempertahankan bentuk nilai asli, termasuk nol di depan ID anggota. Pada fase ini belum dilakukan penghapusan baris atau perubahan nilai.

Hasil Profiling dan pemeriksaan duplikasi.
Berdasarkan pemeriksaan sel kosong dan nilai string kosong ditemukan **138** nilai kosong pada kolom **penghasilan_juta** memiliki persentase **9,2%** dari seluruh anggota.
File anggota.csv tidak memiliki duplikasi identik maupun ID yang berulang namun pada transaksi.csv ditemukan **535** ID transaksi yang masing-masing muncul 2 kali, sehingga terdapat **1.070 baris yang terlibat pada pengulangan ID transaksi**. Pengulangan tersebut berupa 535 salinan baris identik tambahan.

Salinan identik dihapus dengan mempertahankan satu kemunculan setiap transaksi. Jumlah baris transaksi berkurang dari 36.175 menjadi 35.640, sedangkan jumlah baris anggota tetap 1.500. Setelah langkah tersebut, tidak terdapat ID transaksi berulang yang tersisa.

Langkah pembersihan	Anggota sebelum	Anggota sesudah	Transaksi sebelum	Transaksi sesudah

Menghapus salinan identik transaksi	1.500	1.500	36.175	35.640
Memisahkan transaksi tanpa pasangan untuk analisis anggota	1.500	1.500	35.640	35.400
Menandai usia tidak valid sebagai missing	1.500	1.500	35.400	35.400
Menangani penghasilan kosong	1.500	1.500	35.400	35.400

Sebanyak 240 transaksi tanpa pasangan tetap disimpan sebagai data pengecualian. Audit nominal dilakukan pada 35.640 transaksi setelah deduplikasi, sedangkan pembentukan fitur anggota menggunakan 35.400 transaksi yang memiliki pasangan pada tabel anggota. Penanganan usia dan penghasilan tidak menghapus anggota.

Setelah deduplikasi **transaksi memiliki 1.559 ID anggota berbeda.** Pemeriksaan kecocokan ID menemukan 240 transaksi dari 60 ID yang tidak ditemukan secara persis pada tabel anggota. Transaksi tersebut dipisahkan sebagai data pengecualian dan tidak digunakan untuk membentuk fitur anggota.

Ringkasan masalah dan keputusan penanganan.

Masalah	**Jumlah baris terdampak**	**Keputusan**	**Alasan**
Salinan identik transaksi	1.070 baris pengulangan ID transaksi. 535 salinan tambahan.	Mempertahankan kemunculan pertama setiap transaksi identik	Mencegah transaksi yang sama dihitung berulang.
ID anggota pada transaksi tidak ditemukan pada tabel anggota	240 transaksi dari 60 ID anggota	Memisahkan sebagai data pengecualian dan tidak menggunakannya untuk fitur anggota yang tersedia	Transaksi tidak dapat dihubungkan dengan atribut dan target anggota.
Penghasilan kosong	138 anggota atau 9,2%	Tambahkan indikator missing. Isi kolom deskriptif menggunakan median kelompok usia dan fallback median keseluruhan	Mempertahankan anggota dan memanfaatkan pola usia yang teramati, dengan keterbatasan imputasi tetap dilaporkan.
Usia di luar rentang 17–70 tahun	44 anggota: 26 bernilai -1 dan 18 bernilai 999	Tandai sebagai missing. Pertahankan anggota	Nilai tidak sesuai rentang usia dalam tugas.

Dugaan salah skala nominal	9 transaksi	Tandai untuk klarifikasi dan simpan nominal asli	Satu item tercatat Rp22–35 juta, jauh di atas nilai per item transaksi pembanding
Total nol	7 transaksi	Tandai untuk klarifikasi; simpan nominal asli	Belum diketahui apakah transaksi gratis, pembatalan, atau kesalahan pencatatan
Total negatif	5 transaksi	Tandai untuk klarifikasi; simpan nominal asli	Belum diketahui apakah pengembalian dana, penyesuaian, atau kesalahan pencatatan

b. Mekanisme Hilangnya *penghasilan_juta* dan Penanganannya
Pemeriksaan berdasarkan kelompok usia menunjukkan pola berikut.

Kelompok Usia	**Jumlah Anggota**	**Penghasilan Kosong**	**Persentase Kosong**
17–29	656	20	3,05%
30-39	487	41	8,42%
40–49	207	30	14,49%
50–59	73	30	41,10%
60–70	33	13	39,39%

Tabel menggunakan 1.456 anggota dengan usia valid. 44 usia tidak valid ditandai sebagai missing tanpa menghapus anggota.

Penghasilan lebih sering kosong pada kelompok usia lebih tua, yaitu 3,05% pada usia 17–29 tahun, dibandingkan 41,10% pada usia 50–59 tahun. Pola ini kurang mendukung asumsi MCAR. MAR digunakan sebagai asumsi kerja, yaitu setelah mempertimbangkan informasi yang diamati, terutama usia, kekosongan dianggap tidak lagi bergantung pada nilai penghasilan yang tidak teramati. Namun, MNAR belum dapat disingkirkan karena kemungkinan kekosongan berkaitan dengan penghasilan sebenarnya tidak dapat diperiksa langsung.

c. Hasil Pemeriksaan dan Penanganan Nilai Total
Pemeriksaan dilakukan terhadap 35.640 transaksi setelah penghapusan duplikat identik. Seluruh nilai total dan jumlah_item dapat dikonversi menjadi angka.

status_audit_total	**jumlah_transaksi**
tidak_ditandai	35.619
dugaan_salah_skala	9
total_nol_perlu_klarifikasi	7
total_negatif_perlu_klarifikasi	5

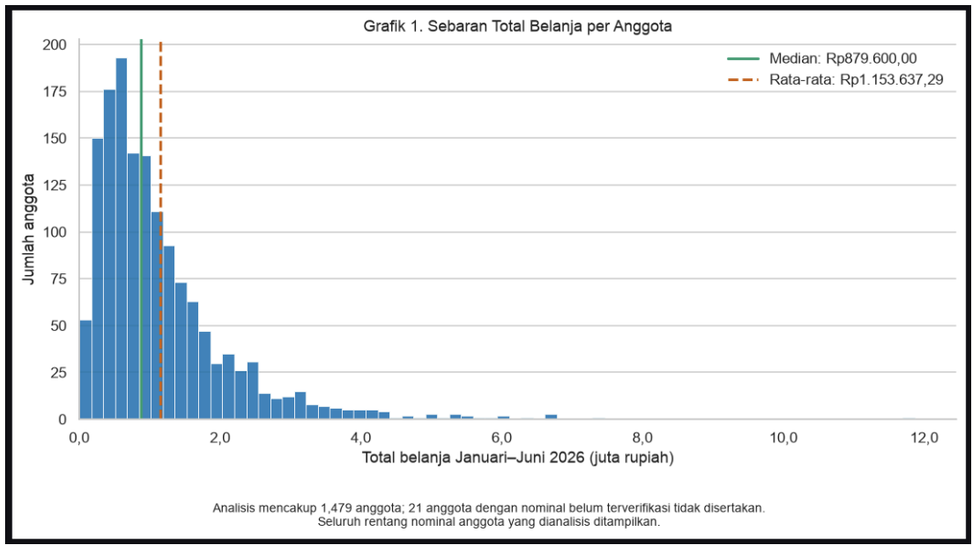
Sebanyak sembilan transaksi satu item dengan total Rp22–35 juta ditandai sebagai dugaan kesalahan skala karena nilai per itemnya jauh di atas transaksi

pembanding. Tujuh transaksi bertotal nol dan lima transaksi bertotal negatif juga ditandai untuk klarifikasi.

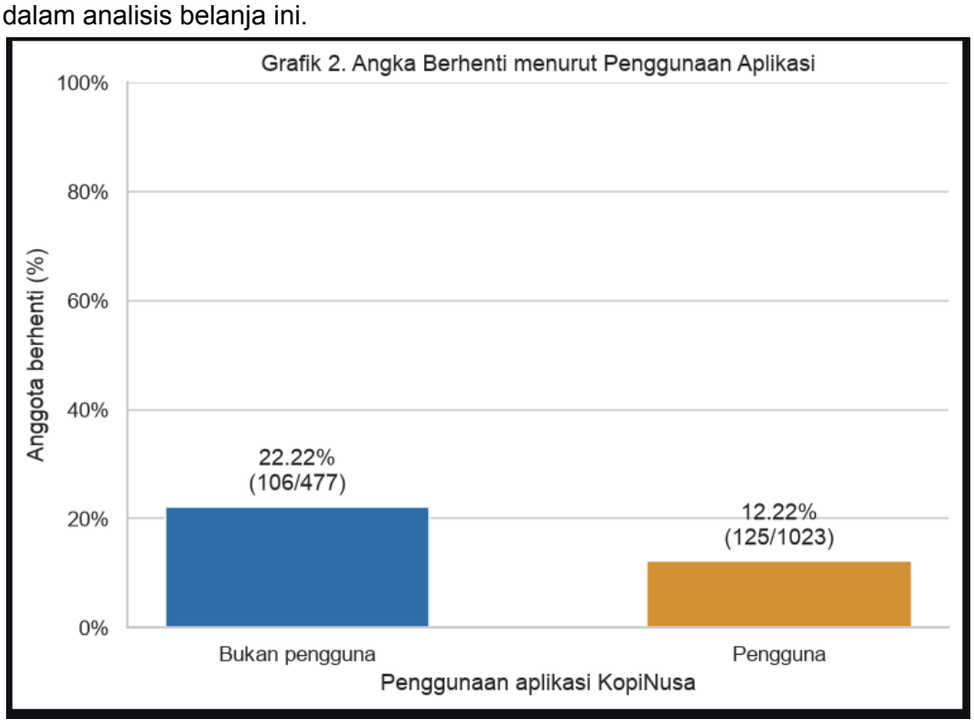
Transaksi bernilai besar tidak langsung dianggap salah. Pemeriksaan mempertimbangkan jumlah item serta nilai total per item dibandingkan transaksi lain. Transaksi besar dengan banyak item dan nilai per item yang sebanding dengan transaksi pembanding dipertahankan sebagai transaksi yang masih masuk akal. Status sah atau salah secara pasti tetap memerlukan verifikasi terhadap struk atau sumber data.

Penanganan pada tahap ini hanya berupa pemberian label audit.
Tidak ada baris yang dihapus atau nominal yang dikoreksi. Label *tidak_ditandai* berarti transaksi tidak masuk ke kelompok masalah yang diperiksa.

3.

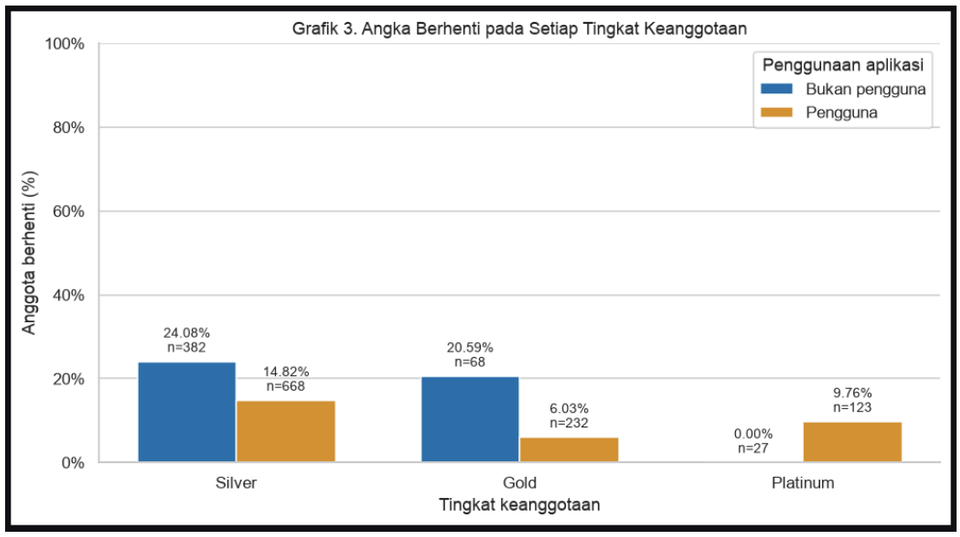


Pada 1.479 anggota yang dianalisis, total belanja Januari – Juni 2026 memiliki distribusi miring ke kanan, dengan rata-rata Rp1.153.637,29 dan median Rp. 879.600,00; median lebih mewakili anggota pada umumnya karena rata-rata tertarik naik oleh sebagian anggota dengan belanja tinggi.
Sebanyak 21 anggota dengan nominal transaksi belum terverifikasi tidak disertakan dalam analisis belanja ini.



Persentase berhenti pada pengguna aplikasi adalah **12,22%** (125 dari 1.023 anggota), lebih rendah dari pada yang bukan pengguna aplikasi sebesar **22,22%** (106 dari 477 anggota), dengan selisih sekitar 10 poin persentase.

Tingkat keanggotaan diperiksa sebagai calon variabel ketiga yang dapat membantu menjelaskan perbedaan angka berhenti antara pengguna dan bukan pengguna aplikasi.



Pada tingkat Silver dan Gold, persentase berhenti pengguna aplikasi lebih rendah daripada bukan pengguna. Pada Platinum, polanya berlawanan: 9,76% pada pengguna dan 0,00% pada bukan pengguna, tetapi kelompok bukan pengguna hanya berjumlah 27 anggota.

Hasil ini tidak menunjukkan pembalikan arah hubungan pada seluruh tingkat seperti pola klasik Simpson's paradox.

4. Peluang berhenti pengguna aplikasi adalah 125/1.023 = 12,22%, sedangkan bukan pengguna aplikasi adalah 106/477 = 22,22%. Selisih pengguna dikurangi dengan bukan pengguna aplikasi adalah -10,003 poin persentase dan dengan selang kepercayaan 95% Newcombe - Wilson [−14,367; −5,895] poin persentase.
   Uji z dua proporsi dua sisi menguji H0: kedua peluang berhenti sama, melawan H1: keduanya berbeda. Hasilnya $z = -4,9986$ dan $p = 5,78 \times 10^{-7}$. Pada $\alpha = 0,05$, $H0$ ditolak.

   Terdapat perbedaan proporsi berhenti yang signifikan secara statistik. Namun, hasil ini belum membuktikan bahwa aplikasi menyebabkan penurunan angka berhenti.

   Untuk mengujinya, bagi anggota yang belum memakai aplikasi secara acak menjadi dua kelompok. Kelompok pertama ditawari aplikasi dan dibantu mengaktifkannya, sedangkan kelompok kedua menerima layanan biasa. Usahakan perbandingan anggota Silver, Gold, dan Platinum serupa pada kedua kelompok serta berikan promo yang sama. Amati selama tiga bulan, lalu bandingkan persentase anggota yang berhenti.

5. **A.** Tabel pemodelan berisi 1.500 anggota dengan satu baris per anggota. Fitur dihitung dari 35.400 transaksi Januari–Juni 2026, sedangkan 240 transaksi tanpa pasangan anggota tidak digunakan. Targetnya adalah status berhenti pada Juli – September 2026.

Fitur	**Definisi**	**Hipotesis perilaku**
recency_days	Hari sejak transaksi terakhir hingga 30 Juni 2026	Semakin lama tidak datang, diduga semakin berisiko berhenti.
frequency	Jumlah transaksi unik	Anggota yang sering bertransaksi diduga lebih mungkin bertahan.
monetary	Rata-rata nominal transaksi	Menggambarkan besarnya belanja setiap transaksi
proporsi_promo	Transaksi memakai promo	Sering memakai promo

	dibagi seluruh transaksi	mungkin menunjukkan ketergantungan pada promo
bulan_aktif	Jumlah bulan yang memiliki transaksi	Aktif pada lebih banyak bulan diduga menunjukkan kunjungan lebih konsisten
proporsi_transaksi_juni	Transaksi Juni dibagi seluruh transaksi Januari – Juni	Proporsi rendah mungkin menunjukkan aktivitas mulai menurun.

B. Encoding dan Scaling

Kolom diproses sesuai jenis datanya. Scaling digunakan agar kolom dengan nilai besar, seperti nominal belanja, tidak mendominasi perhitungan jarak pada kNN.

Kolom	**Perlakuan**
Numerik: usia, penghasilan, lama keanggotaan, dan fitur transaksi	Nilai kosong diisi median data latih, ditambahkan penanda missing, lalu menggunakan `StandardScaler`.
kota	One-hot encoding karena tidak memiliki urutan.
tingkat	Silver = 0 Gold = 1 Platinum = 2 lalu menggunakan StandardScaler.
pakai_aplikasi	Diubah menjadi tidak = 0 dan ya = 1.
penghasilan_was_missing	Dipertahankan sebagai penanda 0/1.
tanggal_daftar	Diubah menjadi lama keanggotaan dalam hari hingga 30 Juni 2026.

Imputasi, encoding kategori, dan scaling dilakukan di dalam Pipeline agar hanya dipelajari dari data latih pada setiap fold. Penghasilan yang sebelumnya diisi untuk analisis deskriptif dikosongkan kembali berdasarkan penanda missing sebelum pemodelan. ID anggota, target, dan voucher_winback tidak digunakan sebagai input model.

C.Perbandingan Himpunan Fitur

Logistic regression dan kNN dibandingkan menggunakan 5-fold cross-validation dengan pembagian fold yang sama.

Himpunan fitur	Logistic regression: ROC-AUC ± SD	kNN (k = 15): ROC-AUC ± SD
A: fitur anggota	0,5915 ± 0,0366	0,5655 ± 0,0496
B: A + frequency dan monetary	0,6075 ± 0,0405	0,5838 ± 0,0365
C: B + recency dan tiga fitur tambahan	0,8226 ± 0,0231	0,7744 ± 0,0268

Penambahan frequency dan monetary hanya sedikit meningkatkan skor. Peningkatan lebih besar terjadi pada himpunan C setelah recency dan tiga fitur perilaku ditambahkan.Logistic regression dengan himpunan C memperoleh rata-rata ROC-AUC tertinggi, yaitu 0,8226. Hasil ini belum menunjukkan fitur tambahan mana yang paling berperan; SD menunjukkan variasi skor antar-fold.

D.Pemeriksaan Kebocoran Data.

Kolom	**Bukti**	**Keputusan dan jenis**

		masalah
id_anggota	Terdapat 1.500 ID unik untuk 1.500 anggota.	Tidak digunakan sebagai fitur karena hanya merupakan pengenal.
berhenti dan target_berhenti	*target_berhenti* sama persis dengan hasil pengubahan berhenti menjadi 0/1.	Digunakan sebagai target, bukan input. Memasukkannya ke input menyebabkan target leakage.
voucher_winback	Voucher dikirim Agustus 2026, setelah batas fitur 30 Juni 2026.	Dikeluarkan dari input karena membocorkan informasi masa depan.

Tabel silang menunjukkan **191 dari 228** penerima voucher berhenti, sedangkan pada bukan penerima terdapat **40 dari 1.272** anggota yang berhenti. Hubungan ini kuat, tetapi tidak membuktikan voucher menyebabkan anggota berhenti. Alasan utama mengeluarkan kolom tersebut adalah waktunya yang melewati batas fitur.

Pemeriksaan daftar input memastikan ketiga himpunan fitur tidak memuat ID, target, atau voucher_winback. Imputasi, encoding, dan scaling juga dilakukan di dalam pipeline untuk mencegah data uji ikut menentukan preprocessing.

E.PCA pada Fitur Numerik

PCA dilakukan pada sembilan fitur numerik setelah nilai kosong diisi median dan fitur menggunakan StandardScaler. Diperlukan tujuh komponen untuk mencapai 90,72% variansi kumulatif. PC1 sendiri menjelaskan 22,47% variansi.

Fitur dominan pada PC1	**Loading**
recency_days	0,6100
bulan_aktif	−0,5428
frequency	−0,4563
proporsi_transaksi_juni	−0,3324

Dengan arah loading tersebut, skor PC1 yang lebih tinggi cenderung menggambarkan anggota yang lebih lama tidak datang, aktif pada lebih sedikit bulan, lebih jarang bertransaksi, dan memiliki proporsi transaksi Juni lebih rendah. Karena itu, PC1 ditafsirkan sebagai ringkasan rendahnya aktivitas kunjungan.

6. Anggota yang lama tidak datang dan semakin jarang bertransaksi layak menjadi perhatian dalam upaya mempertahankan pelanggan. Dalam perbandingan model, informasi aktivitas kunjungan membantu mengenali anggota yang berisiko berhenti lebih baik daripada data anggota dan belanja saja. Pengguna aplikasi memiliki angka berhenti 12,22%, lebih rendah daripada bukan pengguna sebesar 22,22%, tetapi hasil ini belum membuktikan bahwa aplikasi menjadi penyebabnya.

   KopiNusa sebaiknya memprioritaskan pendekatan kepada anggota yang aktivitasnya menurun dan menguji penawaran aplikasi melalui percobaan acak sebelum memperluas program. Dua keterbatasannya adalah sebagian nominal transaksi belum terverifikasi dan hasil analisis hanya berasal dari satu periode pengamatan, sehingga belum tentu berlaku pada periode berikutnya.

Penggunaan AI: Saya menggunakan Perplexity untuk membantu memahami modul, menyusun dan memperbaiki kode notebook, serta merapikan draft laporan. Saya menjalankan kode dan memeriksa hasilnya.